

Por qué la mayoría de los resultados de investigación publicados son falsos

John P. A. Ioannidis

Facultad de Medicina de la Universidad de Ioánina, Ioánina (Grecia)

Facultad de Medicina de la Universidad Tufts, Boston, Massachusetts (Estados Unidos)

Traducción del inglés hecha para el Recetario de Postext · Publicado originalmente en PLoS Medicine 2(8): e124, 30 de agosto de 2005 · doi:10.1371/journal.pmed.0020124 · © 2005 John P. A. Ioannidis, licencia Creative Commons Attribution

RESUMEN

Crece la preocupación por que la mayoría de los resultados de investigación publicados hoy sean falsos. La probabilidad de que una afirmación científica sea cierta puede depender de la potencia del estudio y de su sesgo, del número de estudios que abordan la misma pregunta y, sobre todo, de la proporción entre relaciones verdaderas y relaciones inexistentes entre las que se investigan en cada campo. En este marco, un resultado tiene menos probabilidades de ser cierto cuando los estudios de un campo son más pequeños; cuando los tamaños del efecto son menores; cuando se prueban más relaciones y se seleccionan menos de antemano; cuando hay más flexibilidad en los diseños, las definiciones, las variables de resultado y los modos de análisis; cuando hay más intereses económicos o de otro tipo y más prejuicios, y cuando más equipos trabajan en un campo a la caza de la significación estadística. Las simulaciones muestran que, en la mayoría de los diseños y contextos, es más probable que una afirmación científica sea falsa que verdadera. Además, en muchos campos actuales, los resultados que se proclaman pueden ser a menudo una medida exacta del sesgo dominante. En este ensayo comento lo que estos problemas suponen para la forma de hacer e interpretar la investigación.

Los resultados de investigación publicados a veces quedan refutados por pruebas posteriores, con la confusión y la decepción consiguientes. La refutación y la controversia aparecen en todos los diseños, desde los ensayos clínicos y los estudios epidemiológicos tradicionales [1–3] hasta la investigación molecular más moderna [4, 5]. Cada vez preocupa más que, en la investigación actual, los resultados falsos sean la mayoría, o incluso la inmensa mayoría, de las afirmaciones publicadas [6–8]. Sin embargo, no debería sorprendernos. Se puede demostrar que la mayoría de los resultados que se proclaman son falsos. Aquí examino los factores principales que influyen en este problema y algunos corolarios que se derivan de ellos.

Un modelo para los resultados falsos positivos

Varios metodólogos han señalado [9–11] que la alta tasa de no replicación (falta de confirmación) de los descubrimientos es consecuencia de una estrategia cómoda pero mal fundada: proclamar resultados concluyentes a partir de un único estudio valorado por su significación estadística formal, típicamente con un valor p inferior a 0,05.

Como ya se ha demostrado, la probabilidad de que un resultado sea realmente cierto depende de la probabilidad previa de que lo sea (antes de hacer el estudio), de la potencia estadística del estudio y del nivel de significación estadística [10, 11]. Pensemos en una tabla de 2×2 que compara los resultados de la investigación con el

patrón de referencia de las relaciones verdaderas de un campo científico. En un campo de investigación pueden plantearse hipótesis verdaderas y falsas sobre la existencia de relaciones. Sea R la razón entre el número de «relaciones verdaderas» y el de «relaciones inexistentes» entre las que se prueban en el campo. R es propia de cada campo y puede variar mucho según que el campo busque relaciones muy verosímiles o persiga una sola relación verdadera, o unas pocas, entre los miles o millones de hipótesis que pueden plantearse. Para simplificar el cálculo, consideremos además campos acotados en los que o bien hay una sola relación verdadera (entre las muchas que pueden formularse) o bien la potencia para detectar cualquiera de las varias relaciones verdaderas es parecida. La probabilidad previa al estudio de que una relación sea verdadera es $R/(R+1)$. La probabilidad de que un estudio detecte una relación verdadera es la potencia, $1-\beta$ (uno menos la tasa de error de tipo II). La probabilidad de afirmar una relación cuando no existe ninguna es la tasa de error de tipo I, α . Si en el campo se investigan c relaciones, los valores esperados de la tabla de 2×2 son los de la Tabla 1. Una vez proclamado un resultado por haber alcanzado la significación estadística formal, la probabilidad posterior al estudio de que sea cierto es el valor predictivo positivo, VPP. El VPP es también la probabilidad complementaria de lo que Wacholder y colaboradores han llamado probabilidad de un informe falso positivo [10]. Según la tabla de 2×2 , se obtiene

$$\text{VPP} = \frac{(1-\beta)R}{R-\beta R + \alpha}. \quad (1)$$

Por tanto, un resultado tiene más probabilidades de ser verdadero que falso si $(1-\beta)R > \alpha$. Como la inmensa mayoría de los investigadores trabaja con $\alpha = 0,05$, un resultado es más probablemente verdadero que falso si $(1-\beta)R > 0,05$.

Se tiene menos en cuenta que el sesgo y la repetición de pruebas independientes por distintos equipos de todo el mundo pueden distorsionar aún más este panorama y reducir todavía más la probabilidad de que los resultados sean ciertos. Intentaremos modelizar estos dos factores con tablas de 2×2 semejantes.

El sesgo

Definamos primero el sesgo como la combinación de factores de diseño, de datos, de análisis y de presentación que tienden a producir resultados cuando no deberían producirse. Sea u la proporción de análisis que no habrían sido «resultados», pero que acaban presentándose y comunicándose como tales por culpa del sesgo. El sesgo no debe confundirse con la variabilidad aleatoria, que hace que algunos resultados sean falsos por azar aunque el diseño, los datos, el análisis y la presentación del estudio sean perfectos. El sesgo puede consistir en manipular el análisis o la comunicación de los resultados. La comunicación selectiva o distorsionada es una forma típica de este sesgo. Podemos suponer que u no depende de que exista o no una relación verdadera. No es una suposición descabellada, porque normalmente es imposible saber qué relaciones son de verdad ciertas. En presencia de sesgo (Tabla 2) se obtiene

$$\text{VPP} = \frac{[1-\beta]R + u\beta R}{R + \alpha - \beta R + u - u\alpha + u\beta R}, \quad (2)$$

y el VPP disminuye al aumentar u , salvo que $1-\beta \leq \alpha$, es decir, $1-\beta \leq 0,05$ en la mayoría de las situaciones. Así pues, cuanto mayor es el sesgo, más bajan las probabilidades de que un resultado sea verdadero. La Figura 1 lo muestra para distintas potencias y distintas razones de probabilidades previas al estudio.

Pruebas por varios equipos independientes

Varios equipos independientes pueden estar abordando las mismas preguntas de investigación. Con la globalización de la investigación, es casi la norma que varios equipos, a menudo decenas, estudien preguntas iguales o parecidas. Es fácil estimar la probabilidad de que al menos uno de los estudios hechos sobre una misma pregunta proclame un resultado estadísticamente significativo. Para n estudios independientes de igual potencia, la tabla de 2×2 es la de la Tabla 3:

$$\text{VPP} = \frac{R(1-\beta^n)}{R+1 - [1-\alpha]^n - R\beta^n} \quad (3)$$

Tabla 1. Resultados de la investigación y relaciones verdaderas


Resultado de la investigación	Relación verdadera		
	Sí	No	Total
Sí	$c(1-\beta)R/(R+1)$	$c\alpha/(R+1)$	$c(R+\alpha-\beta R)/(R+1)$
No	$c\beta R/(R+1)$	$c(1-\alpha)/(R+1)$	$c(1-\alpha+\beta R)/(R+1)$
Total	$cR/(R+1)$	$c/(R+1)$	c

Tabla 2. Resultados de la investigación y relaciones verdaderas en presencia de sesgo


Resultado de la investigación	Relación verdadera		
	Sí	No	Total
Sí	$(c[1 - \beta]R + uc\beta R)/(R + 1)$	$c\alpha + uc(1 - \alpha)/(R + 1)$	$c(R + \alpha - \beta R + u - u\alpha + u\beta R)/(R + 1)$
No	$(1 - u)c\beta R/(R + 1)$	$(1 - u)c(1 - \alpha)/(R + 1)$	$c(1 - u)(1 - \alpha + \beta R)/(R + 1)$
Total	$cR/(R + 1)$	$c/(R + 1)$	c

A Potencia 0,80


VPP (%)



B Potencia 0,50



C Potencia 0,20



— $u = 0,05$ — $u = 0,20$ — $u = 0,50$ — $u = 0,80$

Figura 1. VPP (probabilidad de que un resultado de la investigación sea verdadero) en función de la razón de probabilidades previa al estudio para varios niveles de sesgo, u

Los paneles corresponden a una potencia de 0,80, 0,50 y 0,20. Dibujada en código con la ecuación (2) para los valores de u de la leyenda de 2005, con la curva sin sesgo ($u = 0$) en trazo discontinuo; las curvas impresas en 2005 corresponden a $u = 0; 0,05; 0,20$ y $0,80$.

Tabla 3. Resultados de la investigación y relaciones verdaderas cuando hay varios estudios

Resultado de la investigación	Relación verdadera		
	Sí	No	Total
Sí	$cR(1 - \beta^n)/(R + 1)$	$c(1 - [1 - \alpha]^n)/(R + 1)$	$c(R + 1 - [1 - \alpha]^n - R\beta^n)/(R + 1)$
No	$cR\beta^n/(R + 1)$	$c(1 - \alpha)^n/(R + 1)$	$c([1 - \alpha]^n + R\beta^n)/(R + 1)$
Total	$cR/(R + 1)$	$c/(R + 1)$	c

(sin tener en cuenta el sesgo). A medida que aumenta el número de estudios independientes, el VPP tiende a disminuir, salvo que $1 - \beta < \alpha$, es decir, normalmente $1 - \beta < 0,05$. La Figura 2 lo muestra para distintas potencias y distintas razones previas. Para n estudios de potencia distinta, el término β^n se sustituye por el producto de los términos β_i para $i = 1$ hasta n , pero las conclusiones son parecidas.

Corolarios

El recuadro 1 presenta un ejemplo práctico. De las consideraciones anteriores pueden deducirse varios corolarios interesantes sobre la probabilidad de que un resultado de investigación sea realmente cierto.

Corolario 1 **Cuanto más pequeños son los estudios de un campo científico, menos probable es que sus resultados sean ciertos.** Un tamaño muestral pequeño supone una potencia menor y, en todas las funciones anteriores, el VPP de un resultado verdadero disminuye cuando la potencia baja hacia $1 - \beta = 0,05$. Por tanto, en igualdad de condiciones, los resultados son más probablemente ciertos en los campos que hacen estudios grandes, como los ensayos controlados aleatorizados en cardiología (con varios miles de sujetos aleatorizados) [12], que en los campos de estudios pequeños, como la mayor parte de la investigación sobre predictores moleculares (con muestras cien veces menores) [13].

Corolario 2 **Cuanto menores son los tamaños del efecto en un campo científico, menos probable es**




Figura 2. VPP (probabilidad de que un resultado de la investigación sea verdadero) en función de la razón de probabilidades previa al estudio para distintos números de estudios, n

Los paneles corresponden a una potencia de 0,80, 0,50 y 0,20. Dibujada en código con la ecuación [3].

que sus resultados sean ciertos. La potencia depende también del tamaño del efecto. Así, los resultados son más probablemente ciertos en campos con efectos grandes, como el del tabaco sobre el cáncer o la enfermedad cardiovascular (riesgos relativos de 3 a 20), que en campos donde los efectos que se postulan son pequeños, como los factores de riesgo genéticos de las enfermedades poligénicas (riesgos relativos de 1,1 a 1,5) [7]. La epidemiología moderna se ve cada vez más obligada a buscar efectos más pequeños [14]. En consecuencia, cabe esperar que disminuya la proporción de resultados verdaderos.

Corolario 3 **Cuantas más relaciones se prueban en un campo científico, y cuanto menos se seleccionan, menos probable es que sus resultados sean ciertos.** Como hemos visto, la probabilidad posterior de que un resultado sea cierto (el VPP) depende mucho de la razón de probabilidades previa (R). Por eso los resultados

son más probablemente ciertos en los diseños confirmatorios, como los grandes ensayos controlados aleatorizados de fase III o sus metaanálisis, que en los experimentos que generan hipótesis. Los campos que se tienen por muy informativos y creativos por la riqueza de la información que reúnen y analizan, como las micromatrices y otras investigaciones de alto rendimiento orientadas al descubrimiento [4, 8, 15], deberían tener un VPP bajísimo.

Corolario 4 **Cuanta más flexibilidad hay en los diseños, las definiciones, las variables de resultado y los modos de análisis de un campo científico, menos probable es que sus resultados sean ciertos.** La flexibilidad aumenta la posibilidad de convertir en «positivos» resultados que serían «negativos», es decir, el sesgo, u . Para varios diseños, como los ensayos controlados aleatorizados [16–18] o los metaanálisis [19, 20], se ha intentado normalizar cómo se hacen y cómo se comunican.

Recuadro 1. Un ejemplo: ciencia con una razón previa muy baja

Supongamos que un equipo hace un estudio de asociación de genoma completo para averiguar si alguno de 100 000 polimorfismos genéticos se asocia con la predisposición a la esquizofrenia. Por lo que sabemos de la heredabilidad de la enfermedad, es razonable esperar que unos diez de los polimorfismos estudiados estén asociados de verdad con la esquizofrenia, con razones de posibilidades (*odds ratios*) parecidas, de alrededor de 1,3, y con una potencia bastante similar para detectar cualquiera de ellos. Entonces $R = 10/100\,000 = 10^{-4}$, y la probabilidad previa de que un polimorfismo cualquiera esté asociado con la esquizofrenia es también $R/(R+1) = 10^{-4}$. Supongamos además que el estudio tiene una potencia del 60 % para detectar una asociación con una razón de posibilidades de 1,3 con $\alpha = 0,05$. Puede estimarse entonces que, si se encuentra una asociación estadísticamente significativa con un valor p que apenas cruza el umbral de 0,05,

la probabilidad posterior de que sea cierta se multiplica por unos 12 respecto a la previa, pero sigue siendo de solo 12×10^{-4} .

Supongamos ahora que los investigadores manipulan el diseño, los análisis y la comunicación de los resultados para que más relaciones crucen el umbral de $p = 0,05$, aunque no lo habrían cruzado con un diseño y un análisis seguidos al pie de la letra y con una comunicación completa de los resultados, ceñida al plan original del estudio. Con un sesgo $u = 0,10$, la probabilidad posterior de que un resultado sea cierto es de solo $4,4 \times 10^{-4}$. Y aun sin ningún sesgo, cuando diez equipos independientes hacen experimentos parecidos en distintos lugares del mundo y uno de ellos encuentra una asociación formalmente significativa, la probabilidad de que el resultado sea cierto es de solo $1,5 \times 10^{-4}$, apenas mayor que la que teníamos antes de emprender toda esta investigación.

Es probable que seguir unas normas comunes aumente la proporción de resultados verdaderos. Con todo, incluso en los diseños más rigurosos el sesgo parece un problema importante. Por ejemplo, hay pruebas sólidas de que la comunicación selectiva de las variables de resultado, con manipulación de las variables y de los análisis que se publican, es un problema frecuente incluso en los ensayos aleatorizados [21]. Acabar sin más con la publicación selectiva no haría desaparecer el problema.

Corolario 5 Cuantos más intereses económicos o de otro tipo, y más prejuicios, hay en un campo científico, menos probable es que sus resultados sean ciertos. Los conflictos de intereses y los prejuicios pueden aumentar el sesgo, *u*. Los conflictos de intereses son muy frecuentes en la investigación biomédica [22] y suelen declararse de forma insuficiente y escasa [22, 23]. Los prejuicios no tienen por qué tener raíces económicas. Los científicos de un campo pueden tener prejuicios solo por su fe en una teoría o por su apego a sus propios resultados. Investigadores de prestigio pueden impedir, mediante la revisión por pares, que aparezcan y se difundan resultados que refutan los suyos, y condenar así a su campo a perpetuar dogmas falsos. Las pruebas empíricas muestran que la opinión de los expertos es muy poco fiable [24].

Corolario 6 Cuanto más candente es un campo científico (con más equipos trabajando en él), menos probable es que sus resultados sean ciertos. Este corolario, aparentemente paradójico, se sigue de que, como se ha dicho, el VPP de los resultados aislados disminuye cuando muchos equipos trabajan en el mismo campo. Puede explicar por qué a veces vemos un gran entusiasmo seguido rápidamente de fuertes decepciones en los campos que atraen mucha atención. Se ha acuñado el término *fenómeno Proteo* para describir esta rápida alternancia de afirmaciones extremas y refutaciones en sentido opuesto [25]. Las pruebas empíricas indican que esta sucesión de extremos opuestos es muy frecuente en genética molecular [25].

En la mayoría de los diseños y de los campos, la mayoría de los resultados son falsos

En el marco descrito, es bastante difícil conseguir un VPP superior al 50 %. La Tabla 4 recoge los resultados de simulaciones hechas con las fórmulas anteriores, que tienen en cuenta la potencia, la razón entre relaciones verdaderas y no verdaderas y el sesgo, para varias situaciones propias de determinados diseños y contextos. Un resultado de un ensayo controlado aleatorizado bien hecho y con potencia suficiente, que parte de una probabilidad previa del 50 % de que la intervención sea eficaz, resulta cierto alrededor

del 85 % de las veces. De un metaanálisis confirmatorio de ensayos aleatorizados de buena calidad cabe esperar un rendimiento bastante parecido: el sesgo posible probablemente aumenta, pero la potencia y las probabilidades previas son mayores que en un único ensayo. En cambio, un resultado metaanalítico procedente de estudios no concluyentes, en el que se agregan los datos para «corregir» la baja potencia de cada estudio, probablemente es falso si $R \leq 1:3$. Los resultados de ensayos clínicos de fases tempranas con potencia insuficiente serían ciertos una de cada cuatro veces, o menos aún si hay sesgo. Los estudios epidemiológicos de carácter exploratorio salen todavía peor parados, sobre todo cuando les falta potencia, pero incluso los que tienen potencia suficiente pueden tener solo una probabilidad entre cinco de ser ciertos si $R = 1:10$. Por último, en la investigación orientada al descubrimiento con pruebas masivas, en la que las relaciones probadas superan mil veces a las verdaderas (por ejemplo, 30 000 genes estudiados, de los que quizá 30 sean los verdaderos responsables) [26, 27], el VPP de cada relación proclamada es bajísimo, incluso con una normalización considerable de los métodos de laboratorio y estadísticos, de las variables de resultado y de su comunicación para reducir al mínimo el sesgo.

Los resultados que se proclaman pueden ser a menudo una medida exacta del sesgo dominante

Como hemos visto, la mayor parte de la investigación biomédica actual se mueve en terrenos con una probabilidad muy baja, antes y después del estudio, de obtener resultados verdaderos. Supongamos que en un campo de investigación no hay ningún resultado verdadero que descubrir. En un «campo nulo» así, en ausencia de sesgo, lo ideal sería que todos los tamaños del efecto observados variaran por azar en torno al valor nulo. Lo que los resultados observados se aparten de lo esperable por azar sería, sin más, una medida pura del sesgo dominante.

Por ejemplo, supongamos que ningún nutriente ni ningún patrón de alimentación influye de verdad en el riesgo de padecer un tumor determinado. Supongamos también que la literatura científica ha estudiado 60 nutrientes y afirma que todos ellos se relacionan con el riesgo de padecer ese tumor, con riesgos relativos de entre 1,2 y 1,4 al comparar el tercil superior de consumo con el inferior. En tal caso, los tamaños del efecto que se proclaman no miden otra cosa que el sesgo neto que ha intervenido en la producción de esa literatura. De hecho, son la estimación más exacta del sesgo neto. Se sigue incluso que, entre los «campos nulos», los que proclaman efectos más fuertes

Tabla 4. VPP de los resultados de la investigación para varias combinaciones de potencia ($1 - \beta$), razón entre relaciones verdaderas y no verdaderas (R) y sesgo (u)

$1 - \beta$	R	u	Ejemplo práctico	VPP
0,80	1:1	0,10	ECA con potencia adecuada, poco sesgo y una razón previa de 1:1	0,85
0,95	2:1	0,30	Metaanálisis confirmatorio de ECA de buena calidad	0,85
0,80	1:3	0,40	Metaanálisis de estudios pequeños no concluyentes	0,41
0,20	1:5	0,20	ECA de fase I/II con potencia insuficiente, pero bien hecho	0,23
0,20	1:5	0,80	ECA de fase I/II con potencia insuficiente y mal hecho	0,17
0,80	1:10	0,30	Estudio epidemiológico exploratorio con potencia adecuada	0,20
0,20	1:10	0,30	Estudio epidemiológico exploratorio con potencia insuficiente	0,12
0,20	1:1000	0,80	Investigación exploratoria orientada al descubrimiento, con pruebas masivas	0,0010
0,20	1:1000	0,20	Como el anterior, pero con un sesgo más limitado (más normalizada)	0,0015

Los VPP (valores predictivos positivos) estimados suponen $\alpha = 0,05$ para un único estudio; aquí se calculan con la ecuación [2].

ECA, ensayo controlado aleatorizado.

(a menudo acompañados de afirmaciones sobre su importancia médica o para la salud pública) son sencillamente los que han sufrido los peores sesgos.

En los campos con un VPP muy bajo, las pocas relaciones verdaderas apenas alterarían este panorama general. Aunque algunas relaciones sean ciertas, la forma de la distribución de los efectos observados seguiría dando una medida clara de los sesgos que operan en el campo. Esta idea invierte por completo nuestra manera de ver los resultados científicos. Tradicionalmente, los investigadores han recibido con entusiasmo los efectos grandes y muy significativos, como señales de descubrimientos importantes. En la mayoría de los campos de la investigación moderna, unos efectos demasiado grandes y demasiado significativos pueden ser más bien señal de un sesgo grande. Deberían llevar a los investigadores a pensar con espíritu crítico qué puede haber fallado en sus datos, sus análisis y sus resultados.

¿Cómo podemos mejorar la situación?

¿Es inevitable que la mayoría de los resultados de investigación sean falsos, o podemos mejorar la situación? Un

problema importante es que resulta imposible saber con una certeza del 100 % cuál es la verdad en cualquier pregunta de investigación. En este sentido, el patrón «oro» puro es inalcanzable. Aun así, hay varias maneras de mejorar la probabilidad posterior al estudio.

Pueden ayudar unas pruebas con más potencia, como los estudios grandes o los metaanálisis con poco sesgo, porque se acercan más a ese patrón «oro» desconocido. Pero también los estudios grandes pueden tener sesgos, que hay que reconocer y evitar. Hay que tener presente, además, que los estudios enormes pueden encontrar con más facilidad una diferencia formalmente significativa para un efecto trivial que en realidad no se distingue de forma relevante del valor nulo [28–30].

En segundo lugar, la mayoría de las preguntas las abordan muchos equipos, y es engañoso destacar los resultados significativos de un solo equipo. Lo que cuenta es el conjunto de las pruebas. También puede ayudar reducir el sesgo con mejores normas de investigación y frenar los prejuicios, aunque eso quizá exija un cambio de mentalidad científica difícil de lograr. En algunos diseños, como los ensayos aleatorizados, puede dar mejor resultado el registro previo de los estudios [31]. El registro sería un reto para la investigación que genera hipótesis. Dentro de cada campo puede ser más factible algún tipo de registro o de red de colecciones de datos o de investigadores que registrar todos y cada uno de los experimentos que generan hipótesis. En cualquier caso, aunque el registro de estudios no avance mucho en otros campos, los principios de elaborar un protocolo y atenerse a él podrían tomarse de los ensayos controlados aleatorizados mucho más de lo que se hace.

Por último, en lugar de perseguir la significación estadística, deberíamos conocer mejor el intervalo de valores de R (la razón de probabilidades previa al estudio) en el que se mueve la investigación [10]. Antes de hacer un experimento, los investigadores deberían considerar qué probabilidad creen tener de estar probando una relación verdadera y no una inexistente. A veces podrá comprobarse luego si los valores altos de R que se suponían lo son de verdad. Como ya se ha dicho, siempre que sea éticamente aceptable, deberían hacerse estudios grandes y con un sesgo mínimo sobre resultados que se consideran relativamente establecidos, para ver con qué frecuencia se confirman. Sospecho que varios «clásicos» consagrados no superarán la prueba [32].

Con todo, la mayoría de los nuevos descubrimientos seguirán saliendo de investigaciones que generan hipótesis con razones previas bajas o muy bajas. Deberíamos reconocer entonces que la prueba de significación estadística en el informe de un único estudio solo ofrece una imagen

parcial, porque no sabemos cuántas pruebas se han hecho fuera de ese informe y en el conjunto del campo. Pese a la abundante literatura estadística sobre la corrección por comparaciones múltiples [33], normalmente es imposible saber cuánto han rebuscado en los datos los autores, u otros equipos, antes de comunicar un resultado. Y aunque pudiera saberse, eso no nos diría nada sobre la razón previa. Por tanto, es inevitable hacer suposiciones aproximadas sobre cuántas relaciones cabe esperar que sean verdaderas entre las que se prueban en los campos y los diseños de que se trate. Aunque estas suposiciones serían bastante subjetivas, seguirían siendo muy útiles para interpretar las afirmaciones científicas y ponerlas en contexto.

INFORMACIÓN DEL ARTÍCULO

Conflicto de intereses. El autor declara no tener ningún conflicto de intereses. **Abreviatura.** VPP, valor predictivo positivo.

Esta edición. Traducción hecha para el Recetario de Postext de una versión abreviada de J. P. A. Ioannidis, «Why Most Published Research Findings Are False», *PLoS Medicine* 2(8): e124 (2005), doi:10.1371/journal.pmed.0020124; texto original en inglés con licencia Creative Commons Attribution. Se omiten algunas frases y párrafos, las fórmulas van numeradas, las tablas y las figuras se han redibujado y se ha corregido una errata. Compuesto en Gelasio y Sofia Sans Semi Condensed (SIL OFL); fórmulas con MathJax.

REFERENCIAS

- [1] Ioannidis JP, Haidich AB, Lau J. Any casualties in the clash of randomised and observational evidence? *BMJ* 2001;322:879-80.
- [2] Lawlor DA, Davey Smith G, Kundu D, Bruckdorfer KR, Ebrahim S. Those confounded vitamins: what can we learn from the differences between observational versus randomised trial evidence? *Lancet* 2004;363:1724-7.
- [3] Vandenbroucke JP. When are observational studies as credible as randomised trials? *Lancet* 2004;363:1728-31.
- [4] Michiels S, Koscielny S, Hill C. Prediction of cancer outcome with microarrays: a multiple random validation strategy. *Lancet* 2005;365:488-92.
- [5] Ioannidis JPA, Ntzani EE, Trikalinos TA, Contopoulos-Ioannidis DG. Replication validity of genetic association studies. *Nat Genet* 2001;29:306-9.
- [6] Colhoun HM, McKeigue PM, Davey Smith G. Problems of reporting genetic associations with complex outcomes. *Lancet* 2003;361:865-72.
- [7] Ioannidis JP. Genetic associations: false or true? *Trends Mol Med* 2003;9:135-8.
- [8] Ioannidis JPA. Microarrays and molecular research: noise discovery? *Lancet* 2005;365:454-5.
- [9] Sterne JA, Davey Smith G. Sifting the evidence—what's wrong with significance tests? *BMJ* 2001;322:226-31.
- [10] Wacholder S, Chanock S, Garcia-Closas M, El Ghormli L, Rothman N. Assessing the probability that a positive report is false: an approach for molecular epidemiology studies. *J Natl Cancer Inst* 2004;96:434-42.
- [11] Risch NJ. Searching for genetic determinants in the new millennium. *Nature* 2000;405:847-56.
- [12] Yusuf S, Collins R, Peto R. Why do we need some large, simple randomized trials? *Stat Med* 1984;3:409-22.
- [13] Altman DG, Royston P. What do we mean by validating a prognostic model? *Stat Med* 2000;19:453-73.
- [14] Taubes G. Epidemiology faces its limits. *Science* 1995;269:164-9.
- [15] Golub TR, Slonim DK, Tamayo P, Huard C, Gaasenbeek M, et al. Molecular classification of cancer: class discovery and class prediction by gene expression monitoring. *Science* 1999;286:531-7.
- [16] Moher D, Schulz KF, Altman DG. The CONSORT statement: revised recommendations for improving the quality of reports of parallel-group randomised trials. *Lancet* 2001;357:1191-4.
- [17] Ioannidis JP, Evans SJ, Gøtzsche PC, O'Neill RT, Altman DG, et al. Better reporting of harms in randomized trials: an extension of the CONSORT statement. *Ann Intern Med* 2004;141:781-8.
- [18] International Conference on Harmonisation E9 Expert Working Group. ICH Harmonised Tripartite Guideline. Statistical principles for clinical trials. *Stat Med* 1999;18:1905-42.
- [19] Moher D, Cook DJ, Eastwood S, Olkin I, Rennie D, et al. Improving the quality of reports of meta-analyses of randomised controlled trials: the QUOROM statement. *Quality of Reporting of Meta-analyses*. *Lancet* 1999;354:1896-900.
- [20] Stroup DF, Berlin JA, Morton SC, Olkin I, Williamson GD, et al. Meta-analysis of observational studies in epidemiology: a proposal for reporting. Meta-analysis Of Observational Studies in Epidemiology (MOOSE) group. *JAMA* 2000;283:2008-12.
- [21] Chan AW, Hróbjartsson A, Haahr MT, Gøtzsche PC, Altman DG. Empirical evidence for selective reporting of outcomes in randomized trials: comparison of protocols to published articles. *JAMA* 2004;291:2457-65.
- [22] Krinsky S, Rothenberg LS, Stott P, Kyle G. Scientific journals and their authors' financial interests: a pilot study. *Psychother Psychosom* 1998;67:194-201.
- [23] Papanikolaou GN, Baltogianni MS, Contopoulos-Ioannidis DG, Haidich AB, Giannakakis IA, et al. Reporting of conflicts of interest in guidelines of preventive and therapeutic interventions. *BMC Med Res Methodol* 2001;1:3.
- [24] Antman EM, Lau J, Kupelnick B, Mosteller F, Chalmers TC. A comparison of results of meta-analyses of randomized control trials and recommendations of clinical experts. Treatments for myocardial infarction. *JAMA* 1992;268:240-8.
- [25] Ioannidis JP, Trikalinos TA. Early extreme contradictory estimates may appear in published research: the Proteus phenomenon in molecular genetics research and randomized trials. *J Clin Epidemiol* 2005;58:543-9.
- [26] Ntzani EE, Ioannidis JP. Predictive ability of DNA microarrays for cancer outcomes and correlates: an empirical assessment. *Lancet* 2003;362:1439-44.
- [27] Ransohoff DF. Rules of evidence for cancer molecular-marker discovery and validation. *Nat Rev Cancer* 2004;4:309-14.
- [28] Lindley DV. A statistical paradox. *Biometrika* 1957;44:187-92.
- [29] Bartlett MS. A comment on D. V. Lindley's statistical paradox. *Biometrika* 1957;44:533-4.
- [30] Senn SJ. Two cheers for P-values? *J Epidemiol Biostat* 2001;6:193-204.
- [31] De Angelis C, Drazen JM, Frizelle FA, Haug C, Hoey J, et al. Clinical trial registration: a statement from the International Committee of Medical Journal Editors. *N Engl J Med* 2004;351:1250-1.
- [32] Ioannidis JPA. Contradicted and initially stronger effects in highly cited clinical research. *JAMA* 2005;294:218-28.
- [33] Hsueh HM, Chen JJ, Kodell RL. Comparison of methods for estimating the number of true null hypotheses in multiplicity testing. *J Biopharm Stat* 2003;13:675-89.